

BÜYÜK VERİ ANALİTİĞİ, OTOMATİK VERİ ONARIMI VE İSTATİSTİKSEL KARAR DESTEK SİSTEMİ

DataViz: Polars ve SciPy Tabanlı Yerel Büyük Veri Görselleştirme ve Bilimsel İstatistik Stüdyosu

Bu teknik rapor; **DataViz** projesinin yazılım mimarisini, katmanlı modül yapısını, büyük veri (10M–100M+ satır) bellek optimizasyon algoritmalarını, matematiksel/istatistiksel altyapısını ve **TÜBİTAK (2209-A, 2209-B, 1507, 1512 BİGG)** araştırma/Ar-Ge programlarına uygunluk analizini akademik danışman ve hakem değerlendirmesine sunmak üzere kapsamlı biçimde belgelemektedir.

**5 GB /
100M+**

Polars + Sütun İzdüşümü
ile Maksimum Veri
Kapasitesi

50+ Grafik

Akıllı Öneri Motorlu
İnteraktif Plotly.js
Kütüphanesi

SciPy 1.11+

ANOVA, T-Testi,
Korelasyon ve %95
Güven Bantlı Regresyon

**19 / 19
Test**

Uçtan Uca (E2E)
Doğrulanmış API ve
Modül Entegrasyonu

Rapor İçindekiler Rehberi

Bölüm 1: Problem Tanımı, Motivasyon ve Rakip Analizi**Bölüm 3:** Backend Modülleri ve 19 REST API Sözleşmesi**Bölüm 5:** Matematiksel ve İstatistiksel Altyapı (ANOVA, OLS, Healer)**Bölüm 7:** Canlı Uygulama Ekran Görüntüleri ve Arayüz Akışı**Bölüm 2:** Yazılım Mimarisi ve İstemci (Frontend) Modülleri**Bölüm 4:** Büyük Veri Algoritmaları (Column Projection & LRU)**Bölüm 6:** TÜBİTAK Uygunluk, Hakem Kriterleri ve İş Paketleri**Bölüm 8:** Danışman Hoca / Jüri 10 Soru-Cevap Savunma Rehberi**Geliştirici:** Umutcan**Depo (GitHub):**<https://github.com/UmutcaNN00/dataviz>**Teknoloji Yığını:** Python 3.10+, Flask 3.x, Polars, PyArrow, SciPy, Pandas, NumPy, Plotly.js**Mimari Standart:** %100 Yerel (On-Premise / KVKK Uyumlu), Modüler Blueprint & ES6 Mimarisi

1. Problem Tanımı, Motivasyon ve Mevcut Çözümlerle Karşılaştırma

BÖLÜM 01

Akademik araştırmacılar, mühendisler, veri analistleri ve KOBİ'ler; hızla büyüyen veri setlerini temizlemek, görselleştirmek ve istatistiksel olarak doğrulamak zorundadır. Ancak mevcut veri analizi ekosisteminde **dört temel darboğaz** bulunmaktadır:

1. Satır ve Bellek Sınırı (Excel Darboğazı)

Microsoft Excel en fazla **1.048.576 satır** desteklemekte; 200.000 satırın üzerindeki CSV veya XLSX dosyalarında arayüz donmaları yaşanmaktadır. Oysa modern sensör, finans ve e-ticaret kayıtları milyonlarca satırdan oluşmaktadır.

2. Kodlama ve Lisans Bariyeri (SPSS / R / Python)

SPSS, SAS ve Tableau gibi yazılımlar yüksek döviz maliyetli lisanslar gerektirir. R ve Python (Pandas/SciPy) ise kodlama bilgisi olmayan araştırmacılar için yüksek bir öğrenme eşiği oluşturur.

3. Kirli Veri (Dirty Data) ve Tip Bozulmaları

Gerçek dünya verilerinde sayısal sütunlara karışmış **₺5.200**, **1.250.000**, **120kg**, **%85**, **Yok**, **Bilinmiyor** gibi ifadeler tüm sütunun metin (*string/object*) olarak algılanmasına ve analizlerin çökmesine yol açar.

4. Veri Gizliliği (KVKK / GDPR) ve Bulut Riski

Bulut tabanlı BI araçları; hasta verileri, finansal bilançolar veya kurumsal satış kayıtlarının üçüncü parti sunuculara yüklenmesini zorunlu kılar. Bu durum KVKK ve ticari sır güvenliği açısından kritik risk taşır.

💡 DataViz'in Getirdiği Yenilikçi Çözüm

DataViz; tek satır kod yazmadan, **%100 yerel bilgisayarda (sıfır bulut bağımlılığı ile)** çalışan; **Polars + PyArrow** motoruyla milyonlarca satırlık veriyi saniyeler içinde okuyan, **Data Healer** algoritmasıyla bozuk Türkçe/sayısal verileri otomatik onaran, **SciPy** ile parametrik hipotez testlerini (ANOVA, T-Testi, Regresyon) gerçekleştiren ve **50+ interaktif Plotly.js grafiği** ile doğrudan A4 PDF akademik rapor üreten bütünsel bir veri analiz stüdyosudur.


1.1. Mevcut Ticari/Akademik Araçlarla Teknik Karşılaştırma Matrisi

Kriter / Özellik	Microsoft Excel	IBM SPSS	Tableau / PowerBI	R / Python (Kod)	DataViz (Projemiz)
Maksimum Satır Kapasitesi	1.048.576 satır (Sabit sınır)	Donanıma bağlı (Yavaş G/Ç)	Yüksek (Bulut/RAM bağımlı)	Çok Yüksek (Polars/Arrow)	10M – 100M+ Satır (Polars + PyArrow)
Kodlama Gereksinimi	Yok (Formül gerekir)	Yok (Karmaşık menüler)	Düşük (DAX/M dili gerekir)	Yüksek (İleri programlama)	Sıfır Kod (Sürükle-Bırak + Otomatik Öneri)
Türkçe Bozuk Veri Onarımı	Manuel Bul/Değiştir	Yok (Ön işleme şart)	PowerQuery ile manuel kural	Manuel Regex kodlama	Tam Otomatik Data Healer (TR/US + Birim)
Bilimsel Hipotez Testleri	Kısıtlı (Eklenti gerekir)	Tam (ANOVA, T-Test, OLS)	Zayıf (Yalnızca BI odaklı)	Tam (SciPy / Statsmodels)	Tam (ANOVA, T-Test, 5 Model OLS + %95 CI)
Veri Mahremiyeti (KVKK)	Yerel	Yerel	Çoğunlukla Bulut Senkron	Yerel	%100 Yerel (Sıfır Harici Veri Transferi)
Lisans ve Maliyet	Ticari Lisans	Çok Yüksek Döviz Lisansı	Kullanıcı Başı Aylık Abonelik	Açık Kaynak (Ücretsiz)	Açık Kaynak (MIT) / Sıfır Lisans Maliyeti

2. Sistem Mimarisi ve İstemci (Frontend) Modül Yapısı

BÖLÜM 02

DataViz, yazılım mühendisliğinin **Sorumlulukların Ayrılığı (Separation of Concerns - SoC)** ve **Modüler Monolit (Modular Monolith)** prensiplerine uygun olarak **4 ana katmanda** tasarlanmıştır:



2.1. İstemci (Frontend) JavaScript Modül Mimarisi (9 Modül)

İstemci kodu tek bir devasa dosyada toplanmak yerine, bakımı ve test edilebilirliği kolaylaştırmak amacıyla `static/js/` altında **1 Ana Koordinatör (`app.js`)** ve **8 Uzmanlaşmış Modüle** bölünmüştür:

JS Modül Dosyası	Mimari Rolü	Temel Fonksiyonlar ve Sorumluluklar
<code>static/js/app.js</code>	Ana Koordinatör ve Durum Geçiş Yöneticisi	Dosya yükleme (<code>handleFileUpload</code>), örnek veri yükleme (<code>handleLoadSampleData</code>), 3 adım arası ekran geçişleri (<code>proceedToStep2</code> , <code>goToStep3</code>), Excel sayfa geçişleri (<code>switchSheet</code>), Toast bildirimleri ve klavye kısayollarını (<code>1</code> , <code>2</code> , <code>3</code> , <code>R</code> , <code>P</code> , <code>ESC</code>) yönetir.
<code>modules/globals.js</code>	Merkezi Durum (State) Deposu	Uygulama genelinde paylaşılan <code>axisConfig</code> (X/Y eksenleri), <code>activeFilters</code> , <code>dashboardCharts</code> , <code>currentPlotType</code> , <code>numericCols</code> ve <code>categoricalCols</code> durumlarını tutar.
<code>modules/charts_config.js</code>	50+ Grafik Katalogu ve Plotly Çizim Motoru	<code>CHARTS</code> dizisinde 50+ grafik türünün meta verisini tutar. <code>drawMegaPlotly()</code> ve <code>buildLayout()</code> ile Bar, Scatter, Box, Violin, Dumbbell, Lollipop, Gauge, RadialBar, 3D Surface, Treemap, Sunburst ve Candlestick grafiklerini çizer.
<code>modules/chart_manager.js</code>	Sürükle-Bırak, Öneri Motoru ve Çoklu Pano	Sütun havuzu (<code>initDragDropPool</code>), kural tabanlı grafik öneri motoru (<code>evaluateCharts</code>), dinamik dilimleyiciler (<code>renderActiveFilterChips</code>), Formül Sihirbazı ve Çoklu Pano (<code>renderDashboardGrid</code>) yönetimini üstlenir.
<code>modules/data_prep.js</code>	Data Healer ve Veri Temizleme Arayüzü	Anomali rozetlerini (<code>updateAnomalyBadges</code>), sütun onarım modalını (<code>openDataPrepModal</code>), tek tıkla tip onarımını ve eksik veri (NaN) doldurma/silme işlemlerini yürütür.
<code>modules/regression_studio.js</code>	Korelasyon & Regresyon Stüdyosu	Regresyon eğrisi + %95 güven bandı grafiğini (<code>renderRegressionScatter</code>), tıklanabilir korelasyon ısı haritasını (<code>loadCorrelationMatrix</code>), Bento metriklerini ve panoya sabitleme (<code>pinRegressionToDashboard</code>) işlemini yönetir.
<code>modules/pivot_studio.js</code>	Dinamik Pivot Matris Stüdyosu	Satır/Sütun/Değer sürükle-bırak pivot alanlarını, koşullu ısı haritası (Heatmap) renklendirmesini, panoya kopyalamayı ve Excel çıktısını kontrol eder.
<code>modules/join_modal.js</code>	Çoklu Veri Birleştirme (SQL Join)	İkinci veri setinin önizlemesini (<code>/preview_second_file</code>), ortak anahtar sütun seçimini ve <code>Inner/Left/Right/Outer</code> birleştirme işlemini yönetir.
<code>modules/pdf_studio.js</code>	Etkileşimli A4 PDF Rapor Stüdyosu	Panodaki grafikleri yüksek çözünürlüklü açık-tema (baskı dostu) görüntülere dönüştürür, düzenlenebilir metin blokları ekler ve <code>html2pdf.js</code> ile A4 PDF üretir.

3. Backend Kod Mimarisi ve REST API Sözleşmeleri

BÖLÜM 03

Backend mimarisi Python 3.10+ ve Flask 3.x üzerine inşa edilmiştir. Aşağıdaki tabloda sunucu tarafındaki **tüm Python dosyalarının** görevi, içerdiği kritik sınıflar/fonksiyonlar ve mühendislik tasarım kararları detaylı olarak açıklanmıştır:

Dosya Yolu	Temel Sorumluluk	Kritik Fonksiyonlar ve Teknik Detaylar
app.py	Uygulama Fabrikası ve Özel JSON Serileştirici	NumpyJSONProvider sınıfı ile NumPy skaler tiplerini (<code>int64</code> , <code>float64</code> , <code>bool_</code>) ve <code>NaN</code> / <code>±Inf</code> / <code>pd.NA</code> değerlerini özyinelemeli (recursive) olarak geçerli JSON <code>null</code> değerine dönüştürür; tarayıcıda <code>JSON.parse</code> hatalarını %100 engeller.
core/config.py	Merkezi Yapılandırma	<code>MAX_CONTENT_LENGTH = 5 GB</code> (100M+ satırlık Parquet/CSV dosyaları için), <code>ALLOWED_EXTENSIONS = {csv, xlsx, xls, parquet}</code> ve geçici yükleme dizini ayarlarını tutar.
core/store.py	Oturum (Session) Bazlı LRU Bellek Deposu	Her kullanıcıya <code>uuid4</code> atar. <code>DATA_STORE</code> sözlüğünde <code>df</code> (Ana veri), <code>df2</code> (Join verisi) ve Excel sayfalarını tutar. <code>_evict_if_needed()</code> ile <code>MAX_SESSIONS = 10</code> aşıldığında en eski oturumu siler ve <code>gc.collect()</code> ile RAM'i anında işletim sistemine iade eder.
services/file_service.py	Polars/PyArrow Destekli Veri Okuma Motoru	<code>read_parquet_safely()</code> , <code>read_csv_safely()</code> , <code>read_excel_safely()</code> , <code>clean_dataframe()</code> . CSV okurken <code>utf-8-sig</code> , <code>cp1254</code> , <code>iso-8859-9</code> , <code>latin-1</code> kodlamalarını ve <code>;</code> , <code> </code> ayraçlarını otomatik dener. Polars C-motoru ile okuyup <code>float64</code> → <code>float32</code> küçültmesi (downcasting) yapar.
services/data_healer.py	Akıllı Veri Onarıcı ve Filtreleme Motoru	<code>analyze_dataframe_health()</code> , <code>smart_repair_column()</code> , <code>clean_missing_data()</code> , <code>apply_filters()</code> . Sayısal sütunlara karışmış <code>₺</code> , <code>\$</code> , <code>kg</code> , <code>adet</code> , <code>TR/US</code> binlik ayraçları ve sözel NaN ifadelerini tespit edip onarır.
services/stats_service.py	Bilimsel İstatistik ve Regresyon Motoru	<code>calculate_advanced_stats()</code> (ANOVA, T-Testi), <code>calculate_regression_curve()</code> , <code>calculate_regression_studio()</code> (5 model + %95 güven bandı), <code>calculate_correlation_matrix()</code> , <code>calculate_pivot_table()</code> .
services/ai_service.py	Sıfır-Halüsinasyonlu AI Yorumlayıcı	<code>generate_ai_insight()</code> : SciPy'dan gelen kesin r , R^2 , F ve p değerlerini alarak Türkçe akademik ve yönetici özeti üretir. Sayısal değerler LLM tarafından tahmin edilmez; deterministik hesaplamadan şablona enjekte edilir.
services/export_service.py	Çoklu Format Dışa Aktarma Servisi	<code>export_to_parquet()</code> (Polars/PyArrow ZSTD/Snappy sıkıştırmalı), <code>export_to_excel()</code> , <code>export_to_csv()</code> (<code>utf-8-sig</code> Türkçe karakter korumalı) ve <code>export_pivot_to_excel()</code> .

3.1. REST API Uç Noktaları (19 Adet Doğrulanmış Endpoint)

Metot	Endpoint (Uç Nokta)	Blueprint	İşlevi ve Veri Sözleşmesi
GET	/ ve /analysis	main_bp	Karşılama sayfasını ve 3 adımlı ana Analiz Stüdyosunu sunar.
GET	/health	main_bp	Sunucu ve Polars veri motoru sağlık durumunu (200 OK) döner.
POST	/load_sample	main_bp	Hazır akademik örnek veri setini belleğe yükler ve sütun tiplerini döner.
POST	/upload	upload_bp	CSV, Excel veya Parquet dosyasını okur, temizler ve özet şemayı döner.
POST	/select_sheet	upload_bp	Çok sayfalı Excel dosyalarında aktif çalışma sayfasını değiştirir.
GET	/check_health	data_bp	Sütunlardaki eksik veri (NaN) sayılarını ve onarılabılır tip anomalilerini raporlar.
POST	/repair_column_anomalies	data_bp	Data Healer ile bozuk metin/sayı sütunlarını temizler ve float64'e çevirir.
POST	/clean_data	data_bp	Eksik verileri (NaN) ortalama, medyan, mod, sıfır ile doldurur veya satırları siler.
POST	/add_calculated_column	data_bp	Formül Sihirbazı: İki sütun veya sabit sayı ile (+ - * /) yeni sütun üretir.
POST	/preview_second_file & /merge_datasets	data_bp	İkinci dosyayı yükler ve ortak anahtar sütun üzerinden SQL Join (inner/left/right/outer) yapar.
GET/POST	/get_column_unique_values	chart_bp	Dinamik dilimleyici (Slicer) için sayısal min/max veya kategorik benzersiz değerleri döner.
POST	/get_chart_data	chart_bp	Sütun izdüşümü (Projection) ile yalnız seçili X/Y sütunlarında filtre + gruplama yapıp grafik verisi döner.
POST	/get_stats & /get_kpi_summary	stats_bp	Tanımlayıcı istatistikler, çeyreklikler, ANOVA (F, p) ve T-Testi (t, p) sonuçlarını döner.
POST	/get_correlation_matrix	stats_bp	Tüm sayısal sütunlar arasında Pearson, Spearman veya Kendall korelasyon matrisi hesaplar.
POST	/get_regression_studio_data	stats_bp	Doğrusal/Polinom/Log/Üstel regresyon modeli, %95 güven bandı, R ² , SE ve denklem üretir.
POST	/get_ai_insight	stats_bp	Aktif grafik ve istatistik sonuçları için Türkçe akademik ve yönetici yorumu üretir.
POST	/get_pivot_data	stats_bp	Satır, Sütun ve Değer seçimlerine göre çok boyutlu Pivot Matris ve genel toplamaları hesaplar.
POST	/export_data & /export_pivot_excel	export_bp	Filtrelenmiş veriyi Parquet/Excel/CSV olarak veya Pivot matrisi biçimlendirilmiş Excel olarak indirir.

4. Büyük Veri Algoritmaları ve Bellek Optimizasyonu

BÖLÜM 04

Bir akademik danışmanın veya TÜBİTAK hakeminin soracağı en kritik mühendislik sorusu şudur: "Web tabanlı bir Python/Flask uygulaması, 10 milyon veya 100 milyon satırlık bir veriyi RAM'i taşımadan (Out-of-Memory olmadan) ve tarayıcıyı dondurmadan nasıl analiz edebiliyor?" DataViz bu sorunu 4 kademeli mimari optimizasyonla çözer:

1. Sütun İzdüşümü (Column Projection — O(K) Bellek)

Geleneksel uygulamalarda her grafik çiziminde tüm tablo kopyalanır (`df.copy()` → $O(N \times M)$ bellek). DataViz'de `chart_routes.py` ve `stats_service.py`, 50 sütunlu tablonun tamamına dokunmaz; yalnızca kullanıcının seçtiği K adet sütunu (`needed_cols = [x_col] + y_cols`) seçer ve NaN temizliğini yalnız bu alt kümede yapar. Bellek tüketimi **15-20 kat** düşer.

2. Polars + PyArrow Çok İş Parçacıklı (SIMD) Okuma

Apache Arrow bellek formatını kullanan Rust tabanlı **Polars** motoru, CSV ve Parquet dosyalarını tüm CPU çekirdeklerini paralel kullanarak okur. Ayrıca `clean_dataframe()` aşamasında 64-bit kayan noktalı sayılar (`float64`) değer aralığı uygunsa `float32`'ye, tam sayılar `int32/int16`'ya daraltılarak (downcasting) RAM kullanımı **%50 azaltılır**.

3. İstemci Koruma: İstatistik Tam Veride, Çizim Örnekleme

10 milyon noktayı tarayıcıda SVG/DOM olarak çizmek her tarayıcıyı çöktürir. DataViz'de **tüm istatistiksel hesaplamalar, gruplamalar (groupby), ANOVA ve regresyon denklemleri %100 tam veri kümesi üzerinde** hesaplanır; ancak tarayıcıya gönderilen ham dağılım (scatter) noktaları `iloc[:, step]` sistematik örnekleme ile 2.000-5.000 temsili noktaya indirgenir.

4. Oturum Bazlı LRU Tahliyesi ve Açık Çöp Toplama (GC)

`core/store.py` içindeki `_evict_if_needed()` mekanizması, bellekte en fazla `MAX_SESSIONS = 10` aktif oturum tutar. Yeni bir büyük veri yüklendiğinde veya eski oturum düştüğünde DataFrame referansları silinir ve Python `gc.collect()` çağrılarak ayrılan RAM blokları anında işletim sistemine geri verilir.

Veri Büyüklüğü (Satır Sayısı)	Önerilen Dosya Formatı	Yaklaşık Disk Boyutu	RAM Tüketimi (Downcast + Projection)	Okuma & Grafik Yanıt Süresi
100.000 Satır	CSV / XLSX / Parquet	~2 – 15 MB	~25 MB RAM	< 0.3 saniye
1.000.000 Satır (1M)	CSV / Parquet	~20 – 65 MB	~120 MB RAM	0.4 – 1.2 saniye
10.000.000 Satır (10M)	Apache Parquet / CSV	~160 – 600 MB	~0.8 – 1.4 GB RAM	1.2 – 2.8 saniye
50M – 100M Satır	Apache Parquet (ZSTD)	~0.8 – 2.5 GB	~4.5 – 9.0 GB RAM (16+ GB Sistemde)	3.5 – 8.0 saniye

5. Matematiksel, İstatistiksel ve Algoritmik Altyapı

BÖLÜM 05

5.1. Akıllı Veri Onarıcı (Data Healer) Karar Ağacı ve Regex Algoritması

- Sözel Eksik Veri Normalizasyonu:** {"yok", "bilinmiyor", "belirtilmemiş", "boş", "hatalı", "nan", "null", "n/a", "-"} kümesindeki ifadeler büyük/küçük harf duyarsız olarak gerçek `np.nan` değerine dönüştürülür.
- Birim ve Sembol Soyma:** Sayıların başında/sonunda yer alan para birimleri (₺, \$, €, TL, USD), yüzdeler (%) ve bitişik yazılmış birimler (120kg → 120, 45adet → 45, 300mt → 300) Regex ile temizlenir.
- TR / US Binlik ve Ondalık Ayraç Çözümleyici:** Son ayraç virgül ise (1.250.000,75 → TR formatı) noktalar silinip virgül noktaya çevrilir; yalnızca nokta varsa ve 3'erli binlik gruplama örüntüsüne uyuyorsa (1.250.000) noktalar kaldırılarak tam sayı korunur.
- IQR Aykırı Değer Baskılama:** Uç değerler $IQR = Q_3 - Q_1$ ile $[Q_1 - 1.5 \times IQR, Q_3 + 1.5 \times IQR]$ aralığına kırılır (Winsorization).

5.2. Hipotez Testleri (ANOVA & T-Testi) ve %95 Güven Bantlı Regresyon

Bağımsız Örneklem T-Testi ($k = 2$) & ANOVA ($k \geq 3$)

$$t = (\bar{X}_1 - \bar{X}_2) / \sqrt{(s_1^2/n_1 + s_2^2/n_2)} \quad | \quad F = MSB / MSW$$

X ekseninde 2 grup varsa `ttest_ind`, 3+ grup varsa `f_oneway` otomatik seçilir ve $p < 0.05$ anlamlılık sınırı test edilir.

Regresyon %95 Güven Bandı (Leverage Formülü)

$$CI_{95}(x_0) = \hat{y}(x_0) \pm t_{0.975, n-p} \cdot s_e \cdot \sqrt{\left(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum (x_i - \bar{x})^2} \right)}$$

Doğrusal, Polinom (2./3. derece), Logaritmik ve Üstel modellerde veri merkezinden ($\bar{x}$) uzaklaştıkça hiperbolik genişleyen gerçek güven bandı üretilir.

6. TÜBİTAK Açısından Uygunluk ve Hakem Değerlendirme Analizi

BÖLÜM 06

DataViz projesi; teknik derinliği, yerli açık kaynak yazılım ekosistemi oluşturma potansiyeli, KVKK uyumlu yerel büyük veri mimarisi ve bilimsel metodolojisi açısından **TÜBİTAK destek programları değerlendirme kriterlerine** göre detaylı olarak incelenmiştir.

6.1. Hedef TÜBİTAK Programlarına Uygunluk Matrisi

TÜBİTAK Programı	Uygunluk Düzeyi	Gerekçe ve Önerilen Proje Başlığı / Odak Noktası
TÜBİTAK 2209-A (Üniversite Öğrencileri Araştırma Projeleri)	%95 — Çok Yüksek	Önerilen Başlık: "Büyük Ölçekli Veri Setlerinde Otomatik Anomali Onarımı ve İstatistiksel Hipotez Testleri İçin Polars Tabanlı Yerel Görselleştirme ve Karar Destek Platformu". Yabancı lisanslı yazılımlara (SPSS/Tableau) ücretsiz, Türkçe ve açık kaynaklı bir akademik alternatif sunması 2209-A'nın "bilimsel araştırma ve yaygın etki" kriterleriyle tam örtüşmektedir.
TÜBİTAK 2209-B (Sanayiye Yönelik Lisans Araştırma Projeleri)	%92 — Çok Yüksek	Sanayi Ortağı Senaryosu: Bir üretim fabrikası, hastane, lojistik firması veya e-ticaret KOBİ'si ile eşleşerek; şirketin buluta çıkaramadığı milyonlarca satırlık ERP/CRM/Sensör verisini yerel bilgisayarda temizleyen ve anında A4 yönetici raporuna dönüştüren kurumsal BI çözümü olarak sunulabilir.
TÜBİTAK 1512 (BiGG) & 1507 (Teknogirişim & KOBİ Ar-Ge)	%85 — Yüksek	KVKK/GDPR nedeniyle verisini yurt dışı bulut BI servislerine (PowerBI Cloud, Looker) yükleyemeyen finans, sağlık ve savunma sanayii kuruluşları için "On-Premise Zero-Cloud Self-Service BI" ürünü olarak ticarileştirilebilir.

6.2. TÜBİTAK Hakem Değerlendirme Kriterlerine Göre Proje Analizi (4 Boyut)

1. Özgün Değer (Bilimsel & Teknolojik Yenilik)

- Hibrit Polars + SciPy Mimarisi:** Geleneksel tek iş parçacıklı Pandas yerine Rust tabanlı Polars ve PyArrow kullanarak standart dizüstü bilgisayarlarda 10M+ satır analizi.
- Türkçe Veriye Özgü Data Healer:** Türkçe para birimi, nokta/virgül binlik karmaşası, bitişik ölçü birimleri ve Türkçe sözel eksik değerleri otomatik tanıyan özgün kural dizisi.
- Sıfır-Halüsinasyonlu AI Yorumlama:** Üretken yapay zekanın sayı uydurma riskini ortadan kaldıran, SciPy matematiksel çıktıları deterministik olarak metinleştiren hibrit yapı.

2. Yöntem (Mühendislik Metodolojisi)

- O(K) Sütun İzdüşümü:** Bellek karmaşıklığını sütun sayısından (M) bağımsızlaştıran projeksiyon yöntemi.
- Otomatik Kural Tabanlı Grafik Öneri Motoru:** Veri tiplerine (X_{cat} , Y_{num} kombinasyonlarına) göre 50+ grafik içinden istatistiksel olarak doğru görselleştirmeyi öneren karar mekanizması.
- Doğrulanabilir Test Altyapısı:** 19 uçtan uca entegrasyon testi (`test_system_connectivity.py`) ile %100 doğrulanmış API sözleşmeleri.

3. Proje Yönetimi ve Yapılabilirlik (Fizibilite)

- Hazır Çalışan Prototip (TRL 6-7):** Proje fikir aşamasında değil; uçtan uca çalışan, Docker ile konteynerize edilmiş ve gerçek veri setleriyle (10M satır Parquet) test edilmiş olgunluktadır.
- Sıfır GPU / Düşük Donanım Gereksinimi:** Pahalı sunuculara ihtiyaç duymadan 4-8 GB RAM'li standart öğrenci/araştırmacı bilgisayarlarında çalışır.

4. Yaygın Etki (Akademik, Ekonomik & Toplumsal)

- Dışa Bağımlılığın Azaltılması:** Üniversitelerde ve KOBİ'lerde yüksek maliyetli yabancı istatistik/BI paketlerine yerli alternatif.
- 11. ve 12. Kalkınma Planı Uyumu:** "Büyük Veri Analitiği", "Yerli Yazılım Geliştirme" ve "Siber Güvenlik / Veri Mahremiyeti" öncelikli alanlarıyla doğrudan uyumludur.


TÜBİTAK Başvurusunu Daha da Güçlendirecek "Faz-2 Ar-Ge İş Paketleri" (Hocaya Sunulacak Gelişim Planı)

Danışman hoca "Bu çalışan sistemi TÜBİTAK projesine dönüştürürken araştırma paketi olarak üzerine ne ekleyebiliriz?" diye sorarsa şu 3 Ar-Ge iş paketi (İP) sunulmalıdır:


- İP-1 (Out-of-Core Streaming):** Polars `scan_parquet()` (LazyFrame) ve DuckDB entegrasyonu ile veriyi RAM'e hiç yüklemeyen doğrudan disk üzerinden 100M+ satırda akışlı (streaming) sorgulama.
- İP-2 (Otonom Parametrik / Non-Parametrik Test Seçici):** Shapiro-Wilk / Kolmogorov-Smirnov normallik testi ve Levene varyans homojenliği testi sonucunda verinin dağılımına göre otomatik olarak Parametrik (ANOVA / T-Testi) veya Non-Parametrik (Kruskal-Wallis / Mann-Whitney U) test seçen otonom karar ağacı.
- İP-3 (Denetimsiz Makine Öğrenmesi Modülü):** Çok boyutlu aykırı değer tespiti için *Isolation Forest* ve otomatik müşteri/veri segmentasyonu için *K-Means Kümeleme* sekmesi.

7. Uygulama Arayüzü ve Canlı Sistem Ekran Görüntüleri


BÖLÜM 07



Şekil 1: DataViz Karşılama Ekranı ve Canlı OLS Regresyon / ANOVA İstatistik Önizleme Paneli (landing.html)



Şekil 2: Adım 2 — Sürükle-Bırak Veri Havuzu, Formül Sihirbazı, Pivot Stüdyosu ve 50+ Grafik Öneri Motoru (analysis.html)



Şekil 4: Bilimsel Korelasyon & Regresyon Laboratuvarı — %95 Güven Bandı, Korelasyon Isı Haritası, Bento Metrikleri ve AI Raporu

8. Danışman Hoca / Jüri Soru-Cevap Rehberi (10 Kritik Soru & Cevap)

BÖLÜM 08

Soru 1: "Neden sadece Pandas kullanmak yerine Polars ve PyArrow eklediniz?"

Cevap: Pandas tek iş parçacıklı (single-threaded) çalışır ve büyük CSV/Parquet dosyalarını okurken diski ve belleği darboğaza sokar. Rust diliyle yazılmış olan **Polars** ve **PyArrow** ise işlemcinin tüm çekirdeklerini paralel (SIMD vektörizasyonu ile) kullanır. Bu sayede 10 milyon satırlık bir Parquet dosyasını okuma süremiz 25 saniyeden ~1.2 saniyeye düşmektedir.

Soru 2: "10 milyon satırlık bir veri yüklendiğinde tarayıcı (Chrome) neden donmuyor?"

Cevap: Çünkü ham verinin tamamını tarayıcıya JSON olarak göndermiyoruz. Tüm gruplama (aggregation), ANOVA, T-Testi, korelasyon ve regresyon hesaplamaları sunucu tarafında (Backend'de) 10 milyon satırın tamamı üzerinde yapılır. Tarayıcıya ise yalnızca özetlenmiş grup sonuçları veya dağılım grafiklerinde sistematik örneklenmiş (downsampled) 2.000–5.000 temsili nokta gönderilir.

Soru 3: "Grafik çizerken veya filtre uygularken sunucu RAM'i neden şişmiyor?"

Cevap: `routes/chart_routes.py` ve `services/stats_service.py` içinde **Sütun İzdüşümü (Column Projection)** uyguluyoruz. 50 sütunlu bir veri setinde kullanıcı sadece *Kategori* (X) ve *Satış_Tutarı* (Y) seçtiyse, 50 sütunun tamamını kopyalamak yerine yalnızca bu 2 sütunu (`needed_cols`) seçip işlem yapıyoruz. Ayrıca `core/store.py` içinde LRU tahliyesi ve `gc.collect()` ile eski oturumları bellekten otomatik temizliyoruz.

Soru 4: "Veri setinde bozuk Türkçe ifadeler ('₺5.200', '1.250.000', '120kg', 'Yok') varsa sistem nasıl davranıyor?"

Cevap: `services/data_healer.py` modülümüz veri yüklendiği anda her sütunu tarar. Sayısal olması gerektiği halde metin (string) olarak kalmış sütunları tespit eder. Düzenli ifadeler (Regex) ve Türkçe/ABD binlik-ondalık ayraç karar ağacı ile para birimlerini, bitişik ölçü birimlerini (`kg`, `adet`, `m²`) ve sözel boşlukları (`Yok`, `Bilinmiyor`) temizleyerek sütunu gerçek `float64` tipine dönüştürür.

Soru 5: "Yapay Zeka (AI) yorumlayıcısı istatistiksel sonuçları uydurabilir mi (Halüsinasyon riski var mı)?"

Cevap: Hayır, **sıfır halüsinasyon** garantisiyle çalışır. Çünkü matematiksel hiçbir değeri (r , R^2 , F , t , p -değeri, eğim, ortalama) dil modeline hesaplatmıyoruz. Tüm metrikler önce deterministik olarak `SciPy` ve `NumPy` ile kesin olarak hesaplanır; ardından `services/ai_service.py` içindeki akademik kural motorumuz bu kesin sayıları şablonlara yerleştirerek Türkçe akademik ve yönetici yorumuna dönüştürür.

Soru 6: "Regresyon Stüdyosundaki %95 Güven Bandını nasıl hesaplıyorsunuz?"

Cevap: Basit sabit bir sapma kullanmıyoruz; `scipy.stats.t.ppf(0.975, df=n-p)` ile serbestlik derecesine bağlı kritik t değerini alıyor ve her x_0 noktası için standart tahmin hatasını kaldırıp terimiyle ($\sqrt{[1/n + (x_0 - \bar{x})^2 / \sum(x_i - \bar{x})^2]}$) çarpıyoruz. Bu sayede uç noktalarda belirsizlik arttığı için güven bandı hiperbolik olarak genişliyor.

Soru 7: "Neden JSON serileştirmede özel bir sınıf (NumpyJSONProvider) yazdınız?"

Cevap: Python'daki `float('nan')` veya `np.inf` değerleri standart JSON spesifikasyonunda (RFC 8259) geçersizdir ve tarayıcıda `JSON.parse` hatasına yol açar. `app.py` içinde yazdığımız `NumpyJSONProvider` ve `_sanitize_for_json` fonksiyonu, tüm sözlük ve listeleri özyinelemeli tarayarak `NaN`, `Inf` ve `pd.NA` değerlerini güvenli `null` değerine çevirir.

Soru 8: "İki farklı Excel/CSV dosyasını nasıl birleştiriyorsunuz (SQL Join)?"

Cevap: `routes/data_routes.py` içindeki `/preview_second_file` ve `/merge_datasets` uç noktaları ile ikinci dosyayı `df2` olarak oturuma alıyor, ortak anahtar sütunlarını tip uyumluluğuna (string/numeric) göre normalize ediyor ve `Inner`, `Left`, `Right`, `Outer` Join seçenekleriyle birleştirerek yeni sütunları veri havuzuna ekliyoruz.

Soru 9: "Koyu temalı (Dark Mode) grafikler A4 PDF'e aktarılırken neden siyah mürekkep israfı yapmıyor?"

Cevap: `static/js/modules/pdf_studio.js` modülümüz PDF oluşturmadan hemen önce grafiklerin kopyasını alır, arka planlarını şeffaf/beyaz ve yazı tiplerini koyu lacivert (`#0f172a`) baskı temasına çevirip yüksek çözünürlüklü görüntüsünü alır, ardından ekrandaki canlı grafiği tekrar koyu temaya döndürür.

Soru 10: "Sistemin uçtan uca doğru çalıştığını nasıl doğruladınız?"

Cevap: Projede `test_system_connectivity.py` adında 19 adımlı otomatik bir uçtan uca (End-to-End) entegrasyon test paketi bulunmaktadır. Veri yükleme, Data Healer, dinamik dilimleyiciler, formül sihirbazı, grafik üretimi, regresyon eğrisi, ANOVA/T-testi, pivot matris ve Parquet/Excel dışı aktarma uç noktalarının tamamı otomatik test edilmekte ve **19/19 başarıyla** geçmektedir.